ImobScore: aprendizado bayesiano de preferências imobiliárias a partir de escolhas entre pares

Relatório técnico do experimento com participantes · versão para revisão por pares · 09/11/2026, revisado em 10/11/2026

Resumo. Objetivo: verificar se um modelo bayesiano de escolha entre pares, com priori dada por um perfil (persona), prevê as escolhas de uma pessoa melhor que três alternativas quando há poucas escolhas observadas. **Método:** 31 participantes escolheram, em 20 pares aleatórios de imóveis simulados, o que preferiam. Para cada pessoa, 10 pares ficaram reservados para teste e 3, 5 ou 10 dos restantes serviram de treino, em 20 sorteios. Os métodos foram comparados por acurácia e perda logarítmica (log loss), com testes pareados por pessoa (Wilcoxon, correção de Holm em 12 testes). **Resultados:** o motor bayesiano teve acurácia de 64,0% a 65,5% e log loss de 0,64, o único método abaixo de ln 2 = 0,693. Contra a regressão logística, a vantagem em log loss foi grande e significativa em todos os tamanhos de treino (Holm $p < 0{,}001$; $d_z \approx 1{,}1$); a vantagem em acurácia (+2 a +4 pontos) teve p não corrigido entre 0,007 e 0,02, mas não sobreviveu à correção (Holm p de 0,065 a 0,117). Contra a persona sem aprendizado, não houve diferença significativa. A redução da vantagem com mais dados não foi confirmada. Um bootstrap por pessoa levou às mesmas conclusões. Confirmar a vantagem em acurácia sobre a regressão logística exigiria cerca de 30 a 45 pessoas com um único teste pré-registrado, ou 52 a 75 com a família de 12 testes. **Conclusão:** com 3 a 10 escolhas, a abordagem bayesiana produz probabilidades muito mais bem calibradas que a regressão logística regularizada, mas o ganho em acerto sobre a priori da persona é pequeno e incerto nesta amostra.

1. Contexto e pergunta de pesquisa

Buscas imobiliárias costumam pedir filtros explícitos, como faixa de preço e número de quartos. Preferências reais, porém, envolvem trocas entre atributos (quanto de área compensa uma distância maior, por exemplo), que as pessoas têm dificuldade de expressar em números. O ImobScore é um protótipo acadêmico que aprende essas trocas a partir de escolhas binárias: a pessoa vê dois imóveis e indica qual prefere.

O desafio é o início de uso (*cold start*): com 3 a 10 escolhas por pessoa, um modelo estimado só com os dados dela é instável. A proposta é partir de uma priori dada por um perfil escolhido pela pessoa (Família, Investidor ou Estudante) e atualizá-la com as escolhas por inferência bayesiana. A pergunta é se essa combinação prevê escolhas futuras da mesma pessoa melhor que (a) o perfil sozinho, (b) um modelo sem priori estimado só com as escolhas e (c) uma regra simples de pesos iguais.

2. Terminologia e hipóteses

2.1 Termos usados no relatório

Termo	Significado
Par	Dois imóveis mostrados lado a lado; a pessoa escolhe um. É a unidade de observação.
Par de treino	Par cuja resposta o método pode usar para estimar os pesos da pessoa. n_{train} é quantos pares de treino o método recebe (3, 5 ou 10).
Par de teste	Par reservado, nunca usado no treino. O método prevê a escolha e a previsão é comparada com a resposta real. São sempre 10 por pessoa e sorteio.
Sorteio (split)	Uma divisão aleatória dos 20 pares de uma pessoa em teste e treino. Há 20 sorteios por pessoa, com sementes fixas.
Persona	Perfil escolhido pela pessoa. Define a média da priori dos pesos (Apêndice A).
Unidade de análise	A pessoa. Para cada pessoa e método, as métricas dos 20 sorteios são promediadas em um único número antes de qualquer teste.

2.2 Hipóteses de pesquisa

Antes da coleta, o guia do projeto registrou duas hipóteses de pesquisa, numeradas como H1 e H2. Para não confundir com a notação estatística (H_0 nula, H_1 alternativa), aqui elas se chamam **HP1** e **HP2**. Elas dizem o que se espera encontrar; não são testadas diretamente, e sim por meio das hipóteses nulas da seção 2.3.

- **HP1** · O motor bayesiano prevê melhor que a persona sem aprendizado já com 3 a 5 pares de treino.
- **HP2a** · O motor bayesiano prevê melhor que a regressão logística com poucos pares de treino.
- **HP2b** · Essa vantagem sobre a regressão logística diminui à medida que os pares de treino aumentam.

2.3 Hipóteses estatísticas: o que cada teste verifica

Cada teste compara **dois métodos**, em **uma métrica** e **um tamanho de treino**. Para cada pessoa i, calcula-se a diferença d_i entre o desempenho médio do motor e o do outro método nos pares de teste dessa pessoa, com o sinal escolhido para que $d_i > 0$ signifique "o motor foi melhor para a pessoa i". Com 31 pessoas, cada teste tem 31 valores de d_i. Em todos os testes, a hipótese nula é a de que **não existe diferença sistemática entre os dois métodos**:

H_0 (hipótese nula): na população de onde vêm os participantes, os dois métodos têm o mesmo desempenho. Diferenças entre eles numa pessoa são só ruído: d_i tem distribuição simétrica em torno de zero, ou seja, ganhar por x e perder por x são igualmente prováveis. O centro dessa distribuição é $\delta = 0$.

H_1 (hipótese alternativa): há diferença sistemática: a distribuição de d_i está deslocada, $\delta \neq 0$, para qualquer um dos lados (teste bilateral). Assim, um resultado a favor do outro método também seria detectado.

Como se decide: o valor-p é a probabilidade de observar diferenças pelo menos tão grandes quanto as observadas se H_0 fosse verdadeira. H_0 é rejeitada quando o valor-p corrigido por Holm (seção 3.10) é menor que 0,05. Não rejeitar H_0 não prova que os métodos são iguais; só indica que a amostra não basta para afirmar que diferem.

Teste	Origem	Hipótese nula H_0, em palavras
T1	HP1	Com 3 pares de treino, o motor e a persona acertam a mesma proporção dos pares de teste.
T2	HP1	Com 5 pares de treino, o motor e a persona acertam a mesma proporção dos pares de teste.
T3	HP2a	Com 3 pares de treino, o motor e a regressão logística acertam a mesma proporção dos pares de teste.
T4	HP2a	Com 5 pares de treino, o motor e a regressão logística acertam a mesma proporção dos pares de teste.
T5	HP2a	Com 10 pares de treino, o motor e a regressão logística acertam a mesma proporção dos pares de teste.
T6	HP2b	A vantagem do motor sobre a regressão logística em acurácia é a mesma com 3 e com 10 pares de treino (d_i = vantagem com 3 − vantagem com 10).
T7	HP1	Com 3 pares de treino, o motor e a persona têm a mesma log loss nos pares de teste.
T8	HP1	Com 5 pares de treino, o motor e a persona têm a mesma log loss nos pares de teste.
T9	HP2a	Com 3 pares de treino, o motor e a regressão logística têm a mesma log loss nos pares de teste.
T10	HP2a	Com 5 pares de treino, o motor e a regressão logística têm a mesma log loss nos pares de teste.
T11	HP2a	Com 10 pares de treino, o motor e a regressão logística têm a mesma log loss nos pares de teste.
T12	HP2b	A vantagem do motor sobre a regressão logística em log loss é a mesma com 3 e com 10 pares de treino (d_i = vantagem com 3 − vantagem com 10).

Quadro 1 · São 12 testes: HP1 tem 2 tamanhos × 2 métricas (T1, T2, T7, T8); HP2a, 3 × 2 (T3 a T5 e T9 a T11); HP2b, 1 × 2 (T6 e T12). HP1 e HP2a se confirmam quando as H_0 correspondentes são rejeitadas com d_i médio positivo; HP2b, quando T6 ou T12 rejeitam H_0 com diferença positiva.

3. Métodos

3.1 Catálogo de imóveis

O catálogo é simulado: 300 imóveis à venda em Goiânia-GO, em 9 bairros reais, gerados com semente fixa. O tipo (35% casas), os quartos, a área (log-normal em torno de 28 + 22 × quartos m²), banheiros, vagas, idade (0 a 40 anos), itens de lazer, portaria e aceitação de pets são sorteados com regras plausíveis. O preço segue um modelo hedônico: $\ln(\text{preço}) = 8{,}5 + \ln(\text{área}) + 0{,}08 \cdot \text{vagas} - 0{,}03 \cdot \text{distância} - 0{,}006 \cdot \text{idade} + 0{,}05 \cdot \text{lazer} + 0{,}04 \cdot \text{portaria} + \varepsilon$, com $\varepsilon \sim N(0; 0{,}12^2)$. Os cartões não têm fotos; a interface diz que o catálogo é de demonstração.

3.2 Representação dos imóveis

Cada imóvel x vira um vetor t(x) de 12 atributos estruturados: ln(preço), ln(área), quartos, (quartos − 3)², banheiros, vagas, distância do centro (km), idade (anos), casa (0/1), itens de lazer (0 a 3), aceita pet (0/1) e portaria 24 h (0/1). O termo quadrático permite uma preferência com pico no número de quartos. Cada atributo é padronizado de forma robusta sobre o catálogo: $z_j = (t_j - c_j) / s_j$, com c_j a mediana e $s_j = \text{IQR}_j / 1{,}349$. Assim, o imóvel mediano é o vetor zero.

3.3 Modelo de escolha

Usa-se o modelo de Bradley-Terry com utilidade linear e sem intercepto. Cada pessoa tem um vetor de pesos $w \in \mathbb{R}^{12}$, e a probabilidade de ela preferir A a B é

$$P(\text{A preferido a B} \mid w) = \sigma(w^T(z_A - z_B)), \text{ com } \sigma(u) = 1 / (1 + e^{-u}).$$

Sem intercepto, dois imóveis iguais têm 50%; o lado da tela é sorteado e não entra no modelo. É a mesma forma de uma regressão logística sobre a diferença dos vetores, ou de um neurônio sigmoide sem viés.

3.4 Métodos comparados

Método	Pesos usados para prever	Usa o treino?
Motor bayesiano	Distribuição a posteriori de w, com priori $N(\mu_{persona}, 1 \cdot I)$. A previsão é a média de $\sigma(w_s^T d)$ sobre 4.000 amostras w_s do MCMC (3.5).	sim
Regressão logística	Estimativa pontual de w por máxima verossimilhança com penalidade L2 (scikit-learn, C = 1, sem intercepto). Sem a penalidade, com 3 pares separáveis, os pesos divergem. Não usa a persona. É o controle: mesmo modelo, sem priori e sem média sobre amostras.	sim
Média da persona	$w = \mu_{persona}$, a média da priori (Apêndice A).	não
Pesos iguais	$w_j = +1$ ou -1 na direção esperada do atributo (por exemplo, -1 no preço) e 0 onde não há direção óbvia (casa).	não

A penalidade L2 da regressão logística equivale a uma priori N(0, I) centrada no zero. A diferença em relação ao motor está, portanto, na média da priori (zero contra a persona) e na previsão por média sobre a posteriori em vez de uma estimativa pontual.

3.5 Inferência por MCMC

A posteriori $p(w \mid D) \propto p(D \mid w) \cdot p(w)$ não tem forma fechada e é amostrada por Metropolis-Hastings com passeio aleatório gaussiano, proposta $w' = w + h \cdot \sigma \cdot \varepsilon$, com $\varepsilon \sim N(0, I)$. São 16 cadeias iniciadas em pontos sorteados da priori, 1.000 iterações de aquecimento (com o passo h adaptado a cada 50 iterações para aceitação de 30%, e depois fixo) e 2.000 iterações guardadas com desbaste de 8, o que dá 4.000 amostras. Critério de convergência: R-hat dividido < 1,05, tamanho efetivo de amostra (ESS) > 400 e aceitação entre 15% e 50%. Se o critério falha, a amostragem é refeita uma vez com o dobro de iterações.
Nos 1860 ajustes da avaliação (31 pessoas × 3 tamanhos × 20 sorteios), repetidos com as mesmas sementes, 1860 (100,0%) cumpriram o critério. R-hat máximo: mediana 1,032 (maior valor 1,0499); ESS mínimo: mediana 626 (menor valor 400,0); aceitação: mediana 30%.

3.6 Coleta de dados

A coleta foi feita por um site público entre 05/11 e 07/11/2026, com convite no grupo da turma de graduação do autor e em suas redes sociais pessoais (incluindo o Instagram). Responderam colegas e pessoas de outros perfis, mas a proporção é desconhecida, porque nenhum dado pessoal ou demográfico foi coletado. A pessoa lia uma tela inicial, aceitava um termo de consentimento, informava uma faixa de preço e escolhia uma persona. Em seguida respondia a 20 pares. Os pares eram sorteados ao acaso entre os imóveis com preço entre 0,85 × o mínimo e 1,15 × o máximo da faixa informada, sem repetir par e com cada imóvel em no máximo 3 pares; o lado de cada imóvel era sorteado. Na coleta, nenhum modelo escolhia os pares, para que a avaliação não favorecesse nenhum método. Nenhum dado pessoal foi registrado: cada sessão recebeu um código sequencial (P01, P02, ...). As três primeiras pessoas responderam a 25 pares; depois, o total foi reduzido para 20, por relatos de cansaço. O protocolo aceita os dois tamanhos.

3.7 Critérios de inclusão e exclusão

- **Inclusão:** sessão de coleta com pelo menos 20 pares respondidos.
- **Exclusão:** mediana do tempo de resposta por par abaixo de 1 s, considerado insuficiente para ler preço e área de dois imóveis. A regra foi definida e registrada antes de rodar a avaliação, com base apenas nos tempos.

3.8 Protocolo de avaliação

Para cada pessoa e cada um dos 20 sorteios, os pares são embaralhados com semente fixa; os 10 primeiros formam o teste, e os de treino são os n_{train} primeiros dos restantes. Os conjuntos são aninhados: o treino de 5 contém o de 3, e o teste é o mesmo nos três tamanhos (Figura 1). Motor e regressão logística são ajustados só com o treino; persona e pesos iguais não usam o treino, mas são avaliados nos mesmos pares de teste.



Figura 1 · Um sorteio para uma pessoa. Cinza escuro: os 10 pares de teste. Azul, do escuro ao claro: os pares de treino usados com n_{train} = 3, 5 e 10.

3.9 Métricas

- **Acurácia:** fração dos 10 pares de teste em que o método atribui mais de 50% ao imóvel efetivamente escolhido; exatamente 50% vale meio acerto.
- **Perda logarítmica (log loss):** $-(1/10)\ \Sigma \ln p_i$, com p_i a probabilidade atribuída à escolha real, limitada a $[10^{-6}; 1 - 10^{-6}]$. Menor é melhor. Prever sempre 50% dá $\ln 2 = 0{,}693$; valores acima disso indicam previsões confiantes e erradas. Mede calibração, não só acerto.

3.10 Análise estatística

- **Agregação.** Para cada pessoa, método e n_{train}, as métricas são promediadas nos 20 sorteios. Os sorteios de uma mesma pessoa reutilizam os mesmos 20 pares e não são independentes; por isso, a pessoa é a unidade de análise (n = 31), e os sorteios só reduzem a variância de cada média individual.
- **Diferença pareada.** Para cada pessoa, d_i = métrica do motor − métrica do outro método (na log loss, o sinal é invertido para que $d_i > 0$ favoreça o motor).
- **Teste primário: Wilcoxon de postos sinalizados**, bilateral, sobre os 31 valores d_i. Foi escolhido por não exigir normalidade: nas comparações com a persona, as diferenças não são normais (Shapiro-Wilk $p < 0{,}001$).
- **Intervalo de confiança.** IC 95% da média de d_i pelo método t: $m_d \pm t_{0{,}975;\ 30} \cdot s / \sqrt{31}$, com m_d a média de d_i, com $t_{0{,}975;\ 30} = 2{,}042$ e s o desvio padrão amostral das diferenças. O teste t pareado correspondente é reportado como análise de sensibilidade. As faixas das Figuras 3 e 4 usam o mesmo cálculo sobre as médias por pessoa de cada método.
- **Tamanho de efeito:** $d_z = m_d / s$ (d de Cohen para dados pareados).
- **Comparações múltiplas:** correção de Holm-Bonferroni sobre os 12 valores-p primários, com $\alpha = 0{,}05$.
- **Bootstrap por pessoa (sensibilidade).** Cada réplica sorteia 31 pessoas com reposição entre as 31 e recalcula a média de d_i; são 10.000 réplicas com semente fixa. O IC 95% percentil usa os quantis 2,5% e 97,5% das médias reamostradas; o IC BCa corrige viés e assimetria. O bootstrap não supõe normalidade, mas não aumenta a amostra: estima a variabilidade da média com as mesmas 31 pessoas.
- **Reamostrar não cria dados.** Duplicar pessoas para gerar mais linhas, ou tratar os 620 pares pessoa × sorteio como observações independentes, seria pseudorreplicação: o erro padrão encolheria sem informação nova e os valores-p ficariam artificialmente pequenos. Por isso nenhuma das duas coisas foi feita.
- **Tamanho de amostra para estudos futuros.** Para cada teste, estima-se quantas pessoas dariam 80% de poder se o efeito verdadeiro fosse o observado (d_z): de forma analítica, pelo teste t pareado (distribuição t não central), e por simulação do Wilcoxon, sorteando n valores entre os d_i observados, 2.000 vezes por n. Dois níveis: $\alpha = 0{,}05$, para um único teste primário pré-registrado, e $\alpha = 0{,}05 / 12 \approx 0{,}0042$, o primeiro passo do Holm com a família atual de 12 testes.
- **Pré-registro.** As hipóteses, os métodos, as métricas e o protocolo de sorteios foram fixados antes da coleta. A regra de exclusão foi fixada antes da avaliação. A escolha dos testes, do IC e da correção foi feita depois de ver os resultados descritivos, a pedido de um revisor; ela é a análise padrão para este desenho, mas não foi pré-registrada. O bootstrap e a estimativa de tamanho de amostra foram acrescentados depois, também por sugestão de revisão, e não alteram nenhuma decisão.

4. Resultados

4.1 Amostra

Foram abertas 36 sessões de coleta. Três ficaram incompletas (7, 4 e 1 par respondidos) e foram excluídas pelo critério de inclusão. Das 33 completas, duas foram excluídas pelo critério de tempo (Figura 2): P30, que alternou A e B nos 20 pares em 36 s no total, e P09, com 11 de 20 respostas abaixo de 1 s. A amostra analisada tem **31 pessoas**: 28 com 20 pares e 3 com 25.

Personas escolhidas: Família 17, Estudante 10 e Investidor 4. Tempo total por sessão: mediana de 4,4 min (0,8 a 21,5 min). Mediana do tempo por par entre os incluídos: 1,5 a 16 s. Não houve viés de lado: o imóvel da esquerda foi escolhido em 333 de 635 pares (52,4%; teste binomial contra 50%, p = 0,23).

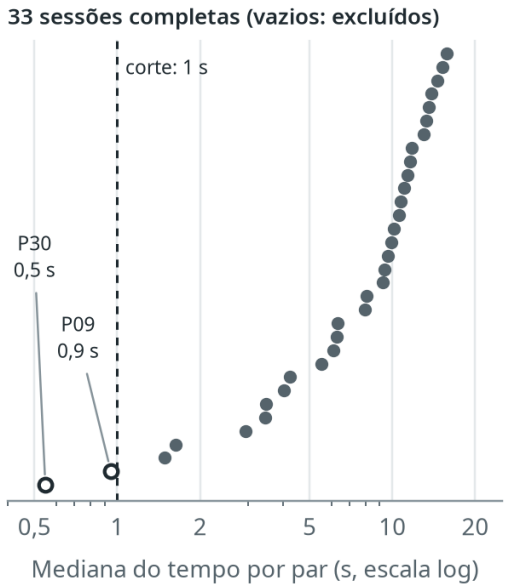


Figura 2 · Mediana do tempo por par, uma sessão por ponto.

4.2 Desempenho por método

	Acurácia (%)			Log loss		
Método	**n = 3**	**n = 5**	**n = 10**	**n = 3**	**n = 5**	**n = 10**
Motor bayesiano	**64,0 ± 5,1**	**64,3 ± 5,1**	**65,5 ± 5,4**	**0,644 ± 0,059**	**0,645 ± 0,067**	**0,642 ± 0,082**
Regressão logística	59,9 ± 4,8	60,8 ± 5,0	63,4 ± 5,5	0,805 ± 0,096	0,840 ± 0,113	0,851 ± 0,142
Média da persona	61,4 ± 6,6	61,4 ± 6,6	61,4 ± 6,6	0,803 ± 0,192	0,803 ± 0,192	0,803 ± 0,192
Pesos iguais	54,2 ± 6,3	54,2 ± 6,3	54,2 ± 6,3	1,629 ± 0,403	1,629 ± 0,403	1,629 ± 0,403

Tabela 1 · Média entre as 31 pessoas ± meia largura do IC 95% (método t). Persona e pesos iguais não usam o treino; seus valores não variam com n.

Figura 3 · Acurácia média por n_train (faixa: IC 95% entre pessoas)

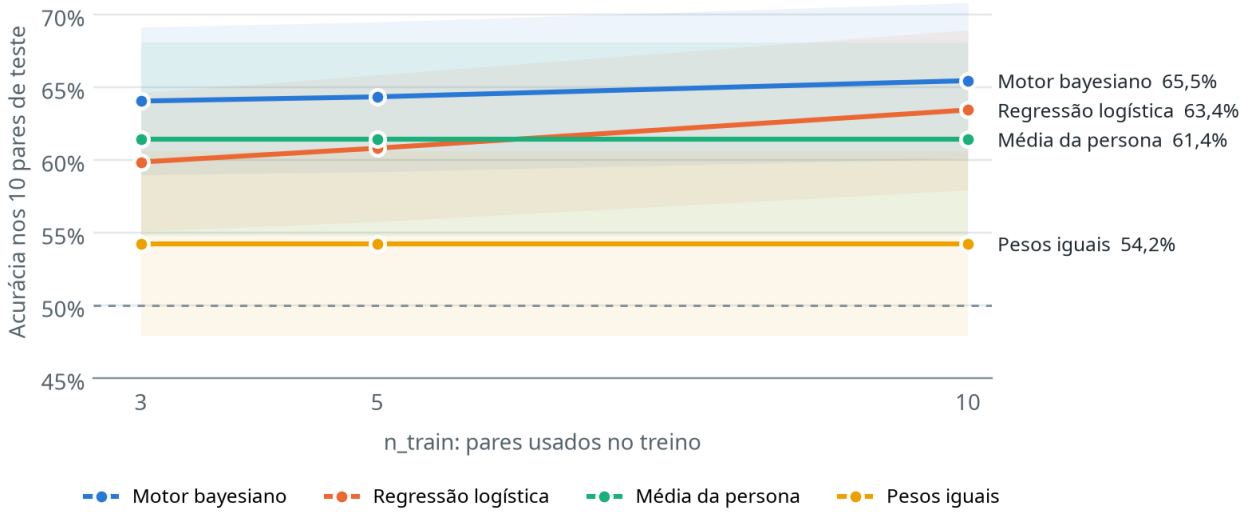
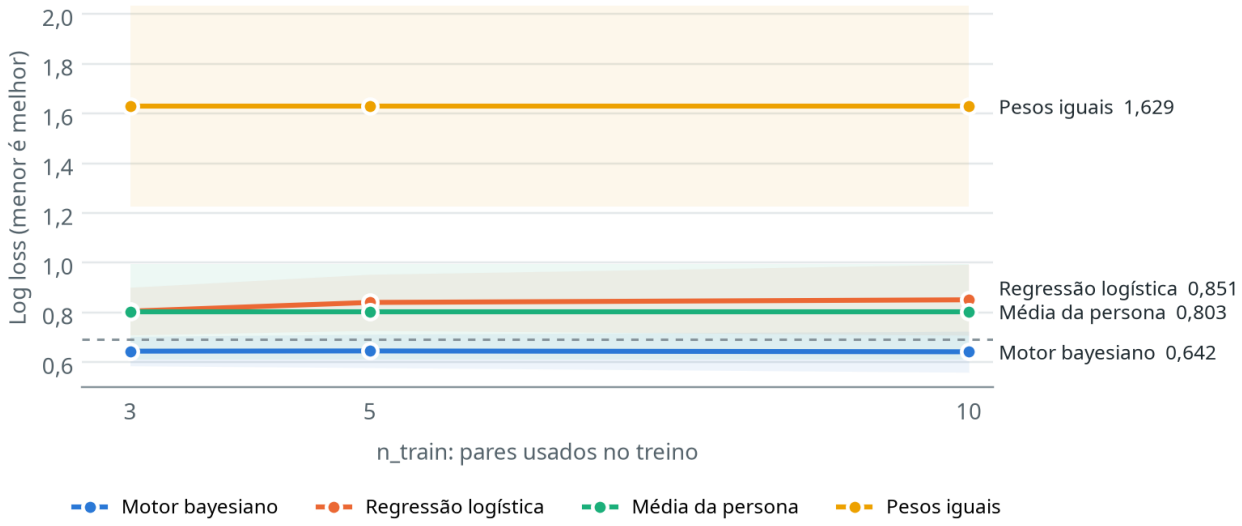


Figura 4 · Log loss média por n_train (tracejado: ln 2, previsão constante de 50%)



A regressão logística ganha acerto com mais pares (de 59,9% para 63,4%), mas sua log loss piora (de 0,805 para 0,851): com mais dados, os pesos estimados crescem e os erros passam a ser cometidos com mais confiança. O motor mantém log loss estável perto de 0,64.

4.3 Testes de hipóteses

Teste · comparação	n	Diferença (IC 95%)	d_z	+ / −	p Wilcoxon	p t	p Holm
Acurácia (pontos percentuais)							
T1 · HP1 · vs. média da persona	3	+2,6 (−1,7; 6,9)	0,22	17 / 13	0,465	0,222	0,598
T2 · HP1 · vs. média da persona	5	+2,9 (−2,2; 8,0)	0,21	17 / 13	0,299	0,252	0,598
T3 · HP2a · vs. regressão logística	3	+4,2 (1,1; 7,3)	0,49	23 / 8	0,008	0,010	0,065
T4 · HP2a · vs. regressão logística	5	+3,5 (1,1; 5,9)	0,54	21 / 9	0,007	0,005	0,065
T5 · HP2a · vs. regressão logística	10	+2,0 (0,3; 3,7)	0,44	21 / 9	0,020	0,019	0,117
T6 · HP2b · queda da vantagem (3 − 10)	3 − 10	+2,2 (−0,2; 4,5)	0,34	19 / 12	0,066	0,067	0,266
Log loss							
T7 · HP1 · vs. média da persona	3	+0,16 (−0,01; 0,33)	0,34	21 / 10	0,014	0,070	0,098
T8 · HP1 · vs. média da persona	5	+0,16 (−0,02; 0,34)	0,32	20 / 11	0,026	0,084	0,130
T9 · HP2a · vs. regressão logística	3	+0,16 (0,11; 0,21)	1,09	27 / 4	< 0,001	< 0,001	**< 0,001**
T10 · HP2a · vs. regressão logística	5	+0,20 (0,13; 0,26)	1,19	26 / 5	< 0,001	< 0,001	**< 0,001**
T11 · HP2a · vs. regressão logística	10	+0,21 (0,14; 0,28)	1,11	28 / 3	< 0,001	< 0,001	**< 0,001**
T12 · HP2b · queda da vantagem (3 − 10)	3 − 10	−0,05 (−0,09; −0,01)	−0,43	11 / 20	0,083	0,024	0,266

Tabela 2 · Diferença = média de d_i (positiva favorece o motor). d_z: tamanho de efeito pareado. + / −: pessoas com $d_i > 0$ e < 0. p Wilcoxon: teste primário, bilateral. p t: teste t pareado (sensibilidade). p Holm: Wilcoxon corrigido para os 12 testes; em negrito quando < 0,05.

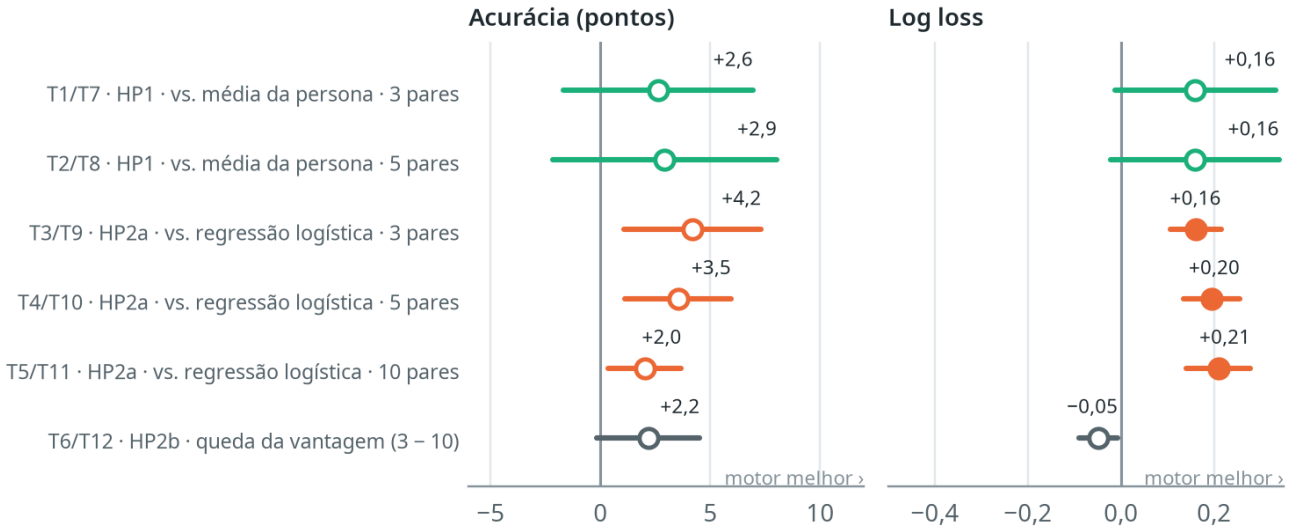


Figura 5 · Diferenças pareadas com IC 95%. Painel esquerdo: testes de acurácia (T1 a T6); direito: log loss (T7 a T12). Círculo cheio: H_0 rejeitada após Holm. Verde: contra a persona (HP1); laranja: contra a regressão logística (HP2a); cinza: queda da vantagem (HP2b).

Decisão sobre cada hipótese, com α = 0,05 após a correção de Holm:

- **HP1 (motor contra persona; T1, T2, T7, T8): nenhuma H_0 rejeitada.** A diferença média em acurácia foi de +2,6 e +2,9 pontos, com IC 95% que inclui o zero e p Wilcoxon de 0,465 e 0,299. Em log loss, o motor foi melhor em média (+0,16), com p não corrigido de 0,014 e 0,026, mas Holm p de 0,098 e 0,130.
- **HP2a (motor contra regressão logística; T3 a T5 e T9 a T11): H_0 rejeitada em T9, T10 e T11, os três testes de log loss** (Holm p < 0,001; d_z de 1,1 a 1,2; motor melhor em 26 a 28 das 31 pessoas). **Em T3 a T5, de acurácia, H_0 não rejeitada após correção**: diferenças de +4,2, +3,5 e +2,0 pontos, todas com IC 95% acima de zero e p não corrigido entre 0,007 e 0,02, mas Holm p de 0,065, 0,065 e 0,117.
- **HP2b (a vantagem diminui; T6 e T12): nenhuma H_0 rejeitada.** Em acurácia, a vantagem caiu 2,2 pontos entre 3 e 10 pares (p = 0,07, sem correção). Em log loss, ela *aumentou* 0,05 (p = 0,08), o oposto do previsto.

4.4 Heterogeneidade entre pessoas

A Figura 6 compara, por pessoa, a acurácia da persona com a do motor. Quando a persona já acerta bem, o motor fica perto dela, porque parte da mesma priori. Quando a persona erra muito, o motor a corrige com poucos pares: em P06, a persona acerta 10% dos pares de teste, e o motor, 64% com 5 pares. Já em P25 o motor ficou abaixo da persona. Com a persona sozinha, 6 pessoas ficaram abaixo de 50% de acurácia, e a log loss média da persona (0,803) é pior que a de uma previsão constante de 50%.

A distribuição das diferenças contra a persona tem caudas longas (Shapiro-Wilk p < 0,001): poucas pessoas com priori muito errada concentram o ganho do motor. Em acurácia, a mediana das diferenças é de +0,5 ponto, contra média de +2,6 (3 pares) e +2,9 (5 pares), e as três maiores diferenças somam mais que o ganho total das 31 pessoas.

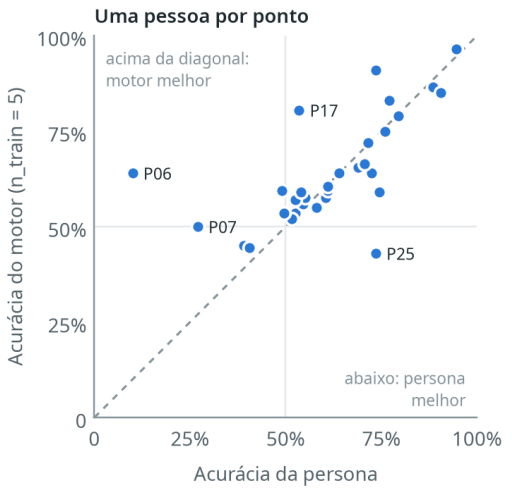


Figura 6 · Acurácia por pessoa, n_{train} = 5.

4.5 Sensibilidade: bootstrap por pessoa

A Tabela 3 compara o IC 95% do método t com os dois IC bootstrap (3.10). Em 10 dos 12 testes, os três intervalos levam à mesma leitura: todos incluem o zero ou todos o excluem. A Figura 7 mostra, à esquerda, um caso típico (T3): a distribuição das médias reamostradas é quase simétrica e os intervalos coincidem.

Teste · comparação	Diferença	IC 95% t	IC 95% bootstrap percentil	IC 95% bootstrap BCa
Acurácia (pontos percentuais)				
T1 · vs. média da persona · 3 pares	+2,6	−1,7 a 6,9	−1,1 a 7,0	−0,6 a 8,0
T2 · vs. média da persona · 5 pares	+2,9	−2,2 a 8,0	−1,6 a 8,1	−1,1 a 8,8
T3 · vs. regressão logística · 3 pares	+4,2	1,1 a 7,3	1,1 a 7,1	1,0 a 6,9
T4 · vs. regressão logística · 5 pares	+3,5	1,1 a 5,9	1,2 a 5,8	1,1 a 5,7
T5 · vs. regressão logística · 10 pares	+2,0	0,3 a 3,7	0,5 a 3,6	0,4 a 3,6
T6 · queda da vantagem (3 − 10) · 3 − 10	+2,2	−0,2 a 4,5	−0,1 a 4,4	−0,1 a 4,3
Log loss				
T7 · vs. média da persona · 3 pares	+0,16	**−0,01 a 0,33**	**0,04 a 0,35**	**0,06 a 0,49**
T8 · vs. média da persona · 5 pares	+0,16	**−0,02 a 0,34**	**0,03 a 0,36**	**0,06 a 0,50**
T9 · vs. regressão logística · 3 pares	+0,16	0,11 a 0,21	0,11 a 0,21	0,11 a 0,21
T10 · vs. regressão logística · 5 pares	+0,20	0,13 a 0,26	0,14 a 0,25	0,14 a 0,25
T11 · vs. regressão logística · 10 pares	+0,21	0,14 a 0,28	0,15 a 0,28	0,15 a 0,28
T12 · queda da vantagem (3 − 10) · 3 − 10	−0,05	−0,09 a −0,01	−0,09 a −0,01	−0,09 a −0,01

Tabela 3 · Intervalos marginais (95% para cada teste isolado, sem correção para 12 testes). Em negrito: os testes em que o IC t e o IC bootstrap discordam sobre incluir o zero.

As exceções são T7 e T8, de log loss contra a persona. O IC t inclui o zero (−0,01 a 0,33 em T7), mas os dois IC bootstrap ficam acima dele (0,04 a 0,35). A causa é uma única pessoa: em P06, a persona erra com confiança e o motor ganha 2,6 de log loss, enquanto nenhuma pessoa perde mais que 0,21. Esse valor extremo infla o desvio padrão, e o IC t, simétrico por construção, estende demais o lado de baixo. Sem P06, a média cai para +0,08 e o próprio IC t fica acima de zero (0,02 a 0,14; em T8, 0,01 a 0,14). A leitura é que o motor dá probabilidades um pouco melhores que a persona sozinha, de forma consistente, mas o efeito é pequeno. Como os intervalos não são corrigidos para 12 comparações, isso não muda a decisão da seção 4.3: T7 e T8 continuam sem rejeitar H_0 após Holm.

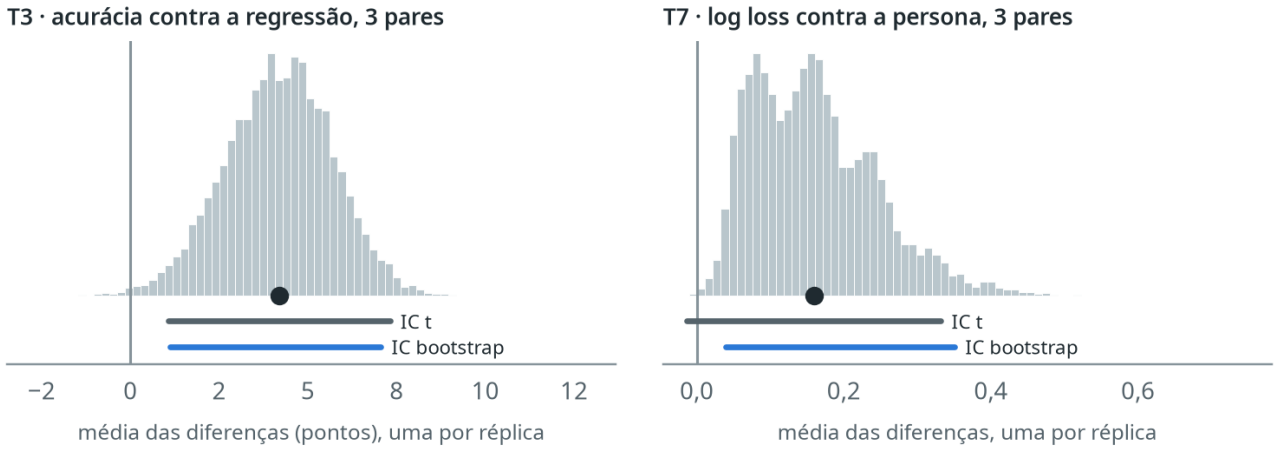


Figura 7 · Distribuição das 10.000 médias reamostradas, com a média observada (ponto preto) e os dois IC 95%. À direita, a cauda longa de T7, causada por P06, desloca o IC t para baixo.

4.6 Tamanho de amostra para um estudo confirmatório

A Tabela 4 estima quantas pessoas dariam 80% de poder a cada teste, supondo que o efeito verdadeiro seja o observado. Não se reporta o poder observado do estudo atual: ele é função direta do valor-p e não acrescenta informação. A estimativa serve para planejar uma nova coleta.

Teste · comparação	d_z	n, um teste (α = 0,05)	n, 12 testes (α = 0,05/12)	n, Wilcoxon simulado (α = 0,05/12)
Acurácia				
T1 · vs. média da persona · 3 pares	0,22	159	279	> 400
T2 · vs. média da persona · 5 pares	0,21	181	317	390
T3 · vs. regressão logística · 3 pares	0,49	35	61	60
T4 · vs. regressão logística · 5 pares	0,54	30	52	55
T5 · vs. regressão logística · 10 pares	0,44	42	75	75
T6 · queda da vantagem (3 − 10) · 3 − 10	0,34	70	123	120
Log loss				
T7 · vs. média da persona · 3 pares	0,34	71	125	70
T8 · vs. média da persona · 5 pares	0,32	79	138	85
T9 · vs. regressão logística · 3 pares	1,09	9	16	20
T10 · vs. regressão logística · 5 pares	1,19	8	14	20
T11 · vs. regressão logística · 10 pares	1,11	9	16	15
T12 · queda da vantagem (3 − 10) · 3 − 10	−0,43	46	80	140

Tabela 4 · Pessoas necessárias para 80% de poder com o efeito observado. As duas primeiras colunas de n usam o teste t pareado; a última simula o Wilcoxon sobre os d_i observados (grade de 5 em 5 até 100 e de 10 em 10 até 400). Em T12 o efeito observado tem o sinal oposto ao de HP2b.

- **Acurácia contra a regressão logística (T3 a T5).** Com d_z de 0,44 a 0,54, um único teste pré-registrado precisaria de 30 a 42 pessoas, perto das 31 disponíveis, o que é coerente com os p não corrigidos de 0,007 a 0,02. Com a família de 12 testes, seriam 52 a 75.
- **Contra a persona em acurácia (T1, T2).** Com $d_z \approx 0{,}2$, seriam 279 a 317 pessoas pelo teste t, e mais de 400 pela simulação, por causa das caudas longas (4.4).
- **Log loss contra a regressão (T9 a T11).** Com $d_z \approx 1{,}1$, de 15 a 20 pessoas bastariam, mesmo com 12 testes; a amostra atual sobra.
- **Ressalva.** O d_z observado com 31 pessoas é impreciso e, entre efeitos que ficaram perto da significância, tende a superestimar o verdadeiro. Os números são uma ordem de grandeza otimista. Um estudo confirmatório deveria pré-registrar um único teste primário e planejar com folga, por exemplo 60 pessoas para T3. Mais pares de teste por pessoa também reduziriam o ruído de cada d_i.

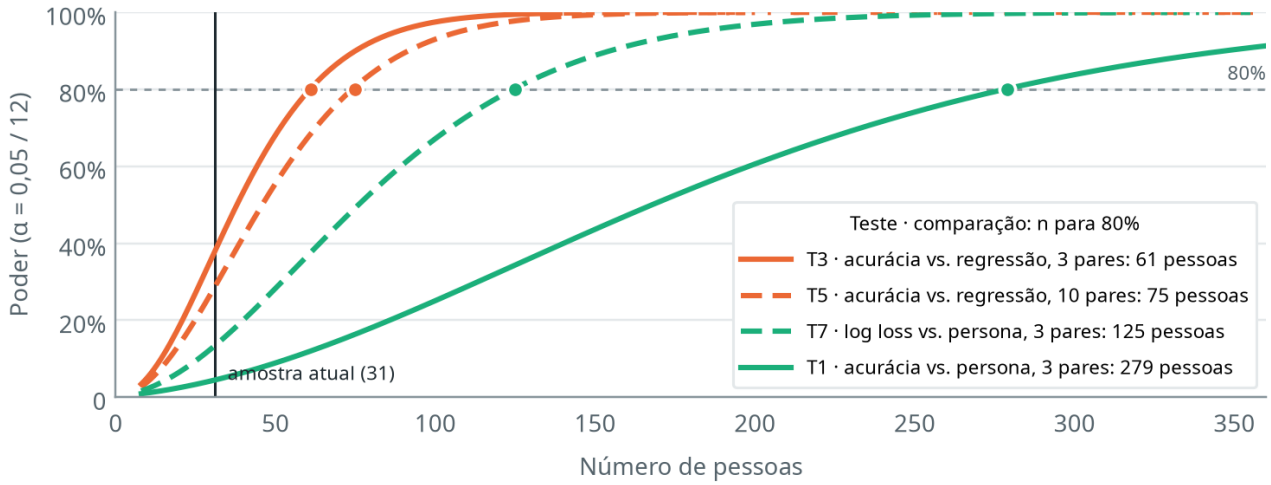


Figura 8 · Poder do teste t pareado em função do número de pessoas, com α = 0,05 / 12 e o efeito observado. Laranja: contra a regressão logística; verde: contra a persona. O ponto marca 80%.

5. Discussão

O resultado mais robusto é a calibração. A regressão logística regularizada, com 3 a 10 pares, produz pesos grandes e previsões extremas; quando erra, erra com confiança, e sua log loss fica acima da de uma previsão constante. O motor bayesiano promedia a previsão sobre a incerteza dos pesos e não tem esse problema: é o único método abaixo de ln 2 em todos os tamanhos. Como os dois métodos usam o mesmo modelo, a diferença vem da priori informativa e da média sobre a posteriori. Para um produto que mostra uma probabilidade ao usuário, essa é a propriedade relevante.

Em acerto, as vantagens são pequenas (2 a 4 pontos) e não sobrevivem à correção para 12 testes. O ganho sobre a persona sem aprendizado é limitado pela própria persona: as prioris foram escritas à mão e estão longe do gosto de parte dos participantes. Com desvio 1 na priori e no máximo 10 pares, o motor se afasta pouco dela (a acurácia sobe só de 64,0% para 65,5% entre 3 e 10 pares). Isso aponta para a calibração das personas com dados reais como o próximo passo, e não para uma falha do método: com uma priori ruim, a inferência bayesiana se comporta como esperado, corrigindo devagar.

6. Limitações e ameaças à validade

- **Validade externa.** Amostra de conveniência de 31 pessoas, recrutadas no grupo da turma do autor e em suas redes sociais; a composição (idade, renda, experiência com compra de imóvel) é desconhecida. Catálogo simulado, sem fotos, de uma única cidade; as escolhas não envolviam compra real. Os resultados não valem para a população nem para portais com anúncios reais.
- **Poder estatístico.** Com n = 31 e 10 pares de teste por pessoa, diferenças de 2 a 3 pontos de acurácia ficam no limite da detecção. A não rejeição de HP1 não demonstra equivalência. A seção 4.6 estima o tamanho necessário para confirmá-las.
- **Validade de construto.** O modelo vê 12 atributos estruturados. O nome do bairro aparecia no cartão, mas o modelo só usa a distância ao centro; a reputação do bairro e outros fatores ficam no termo de erro.
- **Persona autoescolhida.** A persona define a priori e foi escolhida pela própria pessoa; o efeito do motor é condicional a essa escolha.
- **Análise não pré-registrada.** Os testes e a correção foram definidos depois dos resultados descritivos (3.10). A correção de Holm sobre a família completa é conservadora para compensar.
- **Mudança de protocolo.** Redução de 25 para 20 pares após as três primeiras pessoas; essas três têm um conjunto maior de onde os pares de treino são tirados.

7. Reprodutibilidade

Rodada `a6310bac-f944-4a05-8979-d6c84bc75116`. Fonte: backup do banco de produção de 09/11/2026, 18h33, restaurado localmente. Pares exportados em `data/collected/pairs.json` (31 pessoas); resultados por pessoa, método, n e sorteio em `data/results/results.csv` (7.440 linhas). Comandos: `make evaluate` (exportação, avaliação e carga). Todo sorteio usa geradores do NumPy com sementes derivadas por SHA-256 do código da pessoa, de n_{train} e do número do sorteio; a mesma entrada produz os mesmos números. Os testes estatísticos usam SciPy (wilcoxon, ttest_1samp, shapiro, binomtest). O bootstrap usa 10.000 réplicas com semente 20261110 (percentil com NumPy, BCa com scipy.stats.bootstrap); o poder analítico usa scipy.stats.nct, e a simulação do Wilcoxon, 2.000 réplicas por tamanho com semente 1.

Apêndice A · Média da priori de cada persona (escala padronizada; desvio 1 em todos os pesos)

Atributo	Família	Investidor	Estudante
ln(preço)	−1,0	−1,5	−2,0
ln(área)	0,8	0,3	0,2
Quartos	0,6	0,2	−0,2
(Quartos − 3)²	−0,4	−0,2	−0,3
Banheiros	0,4	0,2	0,1
Vagas	0,5	0,2	0,0
Distância do centro	−0,3	−0,8	−1,2
Idade	−0,3	−0,5	−0,1
Casa	0,5	−0,2	−0,3
Lazer	0,4	0,3	0,2
Aceita pet	0,3	0,0	0,2
Portaria 24 h	0,4	0,4	0,1